### I METODI DI DISCESA

## 1. Generalità sui metodi di discesa

Per la risoluzione di un sistema lineare Ax = b con matrice A reale, simmetrica e definita positiva, un'altra famiglia di metodi iterativi è data dai così detti metodi di discesa.

**Nota**: Ricordiamo che dati due vettori colonna  $x, y \in \mathbb{R}^n$  con la notazione  $\langle x, y \rangle si$  intende il prodotto scalare  $x^Ty$ .

Il risultato teorico alla base di questi metodi è il seguente:

### **Teorema 1:**

 $Sia\ A \in \mathbb{R}^{n \times n}$ , matrice simmetrica e definita positiva,  $b, x \in \mathbb{R}^n$ , allora la soluzione del sistema lineare

$$Ax = b \tag{1}$$

coincide con il punto di minimo della seguente funzione quadratica

$$F(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle = \frac{1}{2} x^{T} A x - b^{T} x = \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} x_{i} x_{j} - \sum_{i=1}^{n} b_{i} x_{i}$$

ove la forma quadratica

$$Q(x) = \langle Ax, x \rangle = x^T Ax \ e \ positiva \ per \ x \neq 0.$$

Il teorema afferma quindi che risolvere il sistema (1) equivale a minimizzare la funzione (2).

#### **Dimostrazione:**

Se consideriamo il sistema (1) e definiamo il vettore residuo

$$\underline{r} = Ax-b$$

se  $x^*$  è la soluzione del sistema (1), allora  $r = Ax^* - b = 0$ .

Ora consideriamo la funzione quadratica:

$$F(x) = \frac{1}{2}x^{T}Ax - b^{T}x = \frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}a_{ij}x_{i}x_{j} - \sum_{i=1}^{n}b_{i}x_{i}$$

e cerchiamo il suo punto di minimo.

A questo scopo calcoliamo il gradiente di F ed uguagliamolo a zero:

$$\nabla F = \begin{bmatrix} \frac{\partial F}{\partial x_1} \\ \frac{\partial F}{\partial x_2} \\ \\ \frac{\partial F}{\partial x_n} \end{bmatrix}$$

Sviluppiamo F(x)

$$F(x) = \frac{1}{2}(a_{11}x_1^2 + a_{12}x_1x_2 + \dots + a_{1i}x_1x_i + \dots + a_{1n}x_1x_n + \dots + a_{21}x_2x_1 + a_{22}x_2^2 + \dots + a_{2i}x_2x_i + \dots + a_{2n}x_2x_n + \dots + a_{i1}x_ix_1 + a_{i2}x_ix_2 + \dots + a_{ii}x_i^2 + \dots + a_{in}x_ix_n + \dots + a_{n1}x_nx_1 + a_{n2}x_nx_2 + \dots + a_{ni}x_nx_i + \dots + a_{nn}x_n^2) - (b_1x_1 + b_2x_2 + \dots + b_ix_i + \dots + b_nx_n)$$

Calcoliamo adesso  $\frac{\partial F}{\partial x_i}$ , i = 1, ... n

$$\frac{\partial F}{\partial x_i} = \frac{1}{2}(a_{1i}x_1 + a_{2i}x_2 + \cdots + a_{ni}x_n + a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n) - b_i$$

Per ipotesi la matrice A è simmetrica quindi  $a_{ij} = a_{ji}$ , quindi la precedente relazione si può semplificare in:

$$\frac{\partial F}{\partial x_i} = \frac{1}{2} (2a_{i1}x_1 + 2a_{i2}x_2 + \dots + 2a_{ii}x_i + \dots + 2a_{in}x_n) - b_i$$

cioè

$$\frac{\partial F}{\partial x_i} = a_{i1}x_1 + a_{i2}x_2 + \dots + a_{ii}x_i + \dots + a_{in}x_n - b_i$$
 i=1,...,n

che si può scrivere come

$$\frac{\partial F}{\partial x_i} = \sum_{j=1}^n a_{ij} x_j - b_i = 0 \quad i = 1, ..., n$$

e, in termini vettoriali,

$$\nabla F = Ax-b$$

Poiché abbiamo definito r=Ax-b, risulta che il vettore che annulla il gradiente coincide con la soluzione del sistema lineare, che rende nullo il residuo.

$$r = \nabla F = Ax^* - b = 0.$$

Verifichiamo che il punto che annulla il gradiente è effettivamente un punto di minimo.

A tale scopo calcoliamo la matrice Hessiana H di F:

$$H_{F}(x,y) = \begin{bmatrix} \frac{\partial^{2}F}{\partial x_{1}^{2}} & \frac{\partial^{2}F}{\partial x_{1}\partial x_{2}} & \cdots & \cdots & \frac{\partial^{2}F}{\partial x_{1}\partial x_{n}} \\ \frac{\partial^{2}F}{\partial x_{2}\partial x_{1}} & \frac{\partial^{2}F}{\partial x_{2}^{2}} & \cdots & \frac{\partial^{2}F}{\partial x_{2}\partial x_{n}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^{2}F}{\partial x_{n}\partial x_{1}} & \frac{\partial^{2}F}{\partial x_{n}\partial x_{2}} & \cdots & \frac{\partial^{2}F}{\partial x_{n}^{2}} \end{bmatrix}$$

Osserviamo che, poiché

$$\frac{\partial F}{\partial x_i} = a_{i1}x_1 + a_{i2}x_2 + a_{ii}x_i + \cdots + a_{ij}x_j + \dots + a_{in}x_n - b_i$$
si ha
$$\frac{\partial F}{\partial x_i \partial x_j} = a_{ij} \quad \text{e quindi} \quad H_F(x, y) = A$$

Risulta

$$H_F(x,y) = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \dots & & & & \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}$$

La matrice Hessiana coincide con la matrice A che ha determinate maggiore di zero, ed elemento  $a_{11} > 0$  essendo definita positiva.

Vale infatti il Criterio di Sylvester per le matrici simmetriche e definite positive.

Il criterio di Sylvester è un teorema che fornisce una condizione necessaria e sufficiente affinché una matrice simmetrica sia definita positiva. Stabilisce che una matrice simmetrica è definita positiva se e solo se i determinanti di tutte le sottomatrici principali di testa  $A_k$ , k = 1,...,n sono **positivi**. Poiché la sottomatrice principale di testa di ordine 1 è l'elemento  $a_{11}$  e la sottomatrice principale di testa di ordine n coincide con la matrice A, segue che  $a_{11} > 0$  ed il determinante dell'Hessiano è positivo. Quindi il punto che annulla il gradiente è il minimo della forma quadratica.

Quindi il vettore  $x^*$  che minimizza la funzione F(x) coincide con la soluzione del sistema lineare (1); viceversa la soluzione del sistema (1) con matrice A simmetrica definita positiva minimizza la corrispondente funzione quadratica (2).

## Esempio n=2

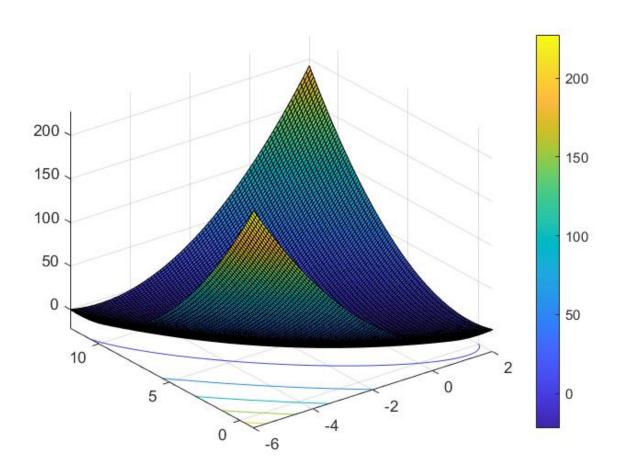
$$A = \begin{bmatrix} 8 & 4 \\ 4 & 3 \end{bmatrix} \quad b = \begin{bmatrix} 8 \\ 10 \end{bmatrix} \quad x = \begin{bmatrix} -2 \\ 6 \end{bmatrix}$$

La matrice A è simmetrica e definita positiva.

Vale il seguente risultato: Forma quadratica associata ad una matrice simmetrica e definita positiva è strettamente convessa, quindi se ammette minimo, esso è unico

$$F(x_1, x_2) = \frac{1}{2} (a_{11}x_1^2 + 2a_{12}x_1x_2 + a_{22}x_2^2) - (b_1x_1 + b_2x_2)$$

### Grafico della forma quadratica associata al sistema lineare Ax=b



Il risultato del teorema 1 ci permette di affermare che per la risoluzione di sistemi lineari con matrice simmetrica definita positiva in generale possono essere usati i metodi per determinare il minimo di una funzione quadratica, noti come **metodi di** discesa.

Questi metodi iterativi consistono nel determinare, a partire da un vettore x al passo k, che indicheremo con  $x^{(k)}$ , un vettore direzione p al passo k,  $p^{(k)}$ , opportuno e nel correggere  $x^{(k)}$  in questa direzione in modo che il valore della funzione quadratica Fnel nuovo iterato  $x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}$  diminuisca, cioè

$$F(x^{(k)} + \alpha^{(k)}p^{(k)}) < F(x^{(k)}).$$

Perché ciò avvenga il parametro  $\alpha^{(k)}$  e la direzione  $p^{(k)}$  devono essere scelti in modo opportuno. I differenti metodi di discesa sono caratterizzati dalla scelta della direzione di discesa  $p^{(k)}$  fra le direzioni di discesa ammissibili.

La determinazione del parametro  $\alpha^{(k)}$  che permette di rendere minima la F nella direzione  $p^{(k)}$  differenzia i metodi suddetti quando vengono impiegati per la soluzione del sistema lineare Ax = b (quindi in cui A sia nota) da quando vengono impiegati per determinare il minimo di una funzione qualsiasi (in cui quindi la matrice A non è nota).

# Un generico algoritmo di discesa per la minimizzazione

- 1. Parti con qualche  $x^{(0)}$ , k = 0
- 2. Determina la direzione di discesa  $p^{(k)}$
- 3. Scegli lo step-size  $\alpha^{(k)}$  tale che

$$F(x^k + \alpha^{(k)} p^{(k)}) < F(x^{(k)})$$
ato

4. Aggiorna l'iterato

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}$$

5. Incrementa il contatore k=k+1

# **→2. <u>Scelta dello step-size</u>**

Nel caso in cui la matrice A sia nota si vede infatti che

$$F(x^{(k)} + \alpha^{(k)}p^{(k)}) = \frac{1}{2} \langle A(x^{(k)} + \alpha^{(k)}p^{(k)}), (x^{(k)} + \alpha^{(k)}p^{(k)}) \rangle -$$

$$\langle b, (x^{(k)} + \alpha^{(k)}p^{(k)}) \rangle$$

$$= \frac{1}{2} \langle Ax^{(k)}, x^{(k)} \rangle + \frac{1}{2}\alpha^{(k)} \langle Ax^{(k)}, p^{(k)} \rangle + \frac{1}{2}\alpha^{(k)} \langle Ap^{(k)}, x^{(k)} \rangle + \frac{1}{2}(\alpha^{(k)})^{2}$$

$$\langle Ap^{(k)}, p^{(k)} \rangle - \langle b, x^{(k)} \rangle - \alpha^{(k)} \langle b, p^{(k)} \rangle$$

Tenendo conto del fatto che  $\langle Ax^{(k)}, p^{(k)} \rangle = \langle Ap^{(k)}, x^{(k)} \rangle$  e ponendo  $r^{(k)} = Ax^{(k)} - b$ , si ha

$$F\left(x^{(k)} + \alpha^{(k)}p^{(k)}\right) = F(x^{(k)}) + \frac{1}{2}(\alpha^{(k)})^2 < Ap^{(k)}, p^{(k)} > +\alpha^{(k)} < r^{(k)}, p^{(k)} > +\alpha^{(k)}, p^{(k)} > +\alpha^{(k)} < r^{(k)}, p^{(k)} > +\alpha^{(k)}, p^{(k)}$$

che è una funzione quadratica in  $\alpha^{(k)}$ .

Per determinarne il valore di  $\alpha^{(k)}$  che rende minima F nella direzione  $p^{(k)}$ , cioè:

$$arg \min_{\alpha^{(k)}} F(x^{(k)} + \alpha^{(k)} p^{(k)})$$

basta considerare

$$\frac{dF}{d\alpha^{(k)}} = \alpha^{(k)} < Ap^{(k)}, p^{(k)} > + < r^{(k)}, p^{(k)} >$$

e uguagliarla a 0; si ottiene per il parametro t il valore

$$\alpha^{(k)} = -\frac{\langle r^{(k)}, p^{(k)} \rangle}{\langle Ap^{(k)}, p^{(k)} \rangle} = -\frac{(r^{(k)})^T p^{(k)}}{(p^{(k)})^T A p^{(k)}}$$
(3)

Questo significa che, una volta determinata la direzione  $p^{(k)}$ , ovvero scelto il metodo di minimizzazione, la relazione (3) ci fornisce il valore da assegnare allo stepsize  $\alpha^{(k)}$  per ottenere il minimo valore possibile della F lungo la direzione  $p^{(k)}$ ,.

Osservazione: il valore di  $\alpha^{(k)}$  fornito dalla (3) ci fornisce un minimo per F in quanto se effettuiamo la derivata seconda in t otteniamo

$$\frac{d^2F}{d\alpha^{(k)^2}} = < Ap^{(k)}, p^{(k)} >$$

che è una quantità positiva per ogni direzione di  $p^{(k)}$ , essendo la matrice A per ipotesi simmetrica e definita positiva.

Nel caso in cui il metodo venga applicato per determinare il minimo di una funzione e quindi la matrice A non sia nota, il valore di  $\alpha^{(k)}$  ottimale si ottiene risolvendo un problema di minimo monodimensionale per la funzione  $F(\alpha^{(k)})$ .

Nel punto di minimo ottenuto usando la formula (3) per il valore del parametro  $\alpha^{(k)}$ abbiamo il seguente risultato:

#### **Teorema:**

Nel punto di minimo  $x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}$ , ottenuto muovendosi lungo la direzione  $p^{(k)}$  con  $\alpha^{(k)}$  dato dalla (3), il vettore residuo  $r^{(k+1)} = Ax^{(k+1)} - b$  risulta ortogonale alla direzione  $p^{(k)}$ , cioè

$$< r^{(k+1)}, p^{(k)} > = 0$$
 (\*)

## **Dimostrazione:**

Essendo

$$r^{(k+1)} = Ax^{(k+1)} - b = A\left(x^{(k)} + \alpha^{(k)}p^{(k)}\right) - b = r^{(k)} + \alpha^{(k)}Ap^{(k)}$$

Si ottiene

$$< r^{(k+1)}, p^{(k)} > = < r^{(k)}, p^{(k)} > + \alpha^{(k)} < A p^{(k)}, p^{(k)} >$$

che risulta 0 scegliendo  $\alpha^{(k)}$  secondo la (3).

$$< r^{(k+1)}, p^{(k)} > = < r^{(k)}, p^{(k)} > - \frac{< r^{(k)}, p^{(k)} >}{< Ap^{(k)}, p^{(k)} >} < Ap^{(k)}, p^{(k)} > = 0$$

## 3. Condizioni di ammissibilità per la direzione di discesa

Per quanto riguarda la scelta delle direzioni di discesa p<sup>(k)</sup> se si considera la relazione

$$\alpha^{(k)} = -\frac{\langle r^{(k)}, p^{(k)} \rangle}{\langle Ap^{(k)}, p^{(k)} \rangle}$$

si può affermare che  $p^{(k)}$  non deve essere ortogonale al residuo  $r^{(k)}$ , o, in modo equivalente, (visto che il gradiente della forma quadratica calcolato in  $x^{(k)}$  è uguale al residuo del sistema lineare valutato in  $x^{(k)}$ ) non deve essere ortogonale al gradiente  $\nabla F(x^{(k)})$ ) di F perché questo porterebbe a  $\alpha^{(k)}=0$ .

Se inoltre consideriamo lo sviluppo in serie di Taylor della  $F(x^{(k)} + \alpha^{(k)}p^{(k)})$ , in un intorno di  $x^{(k)}$ , cioè

$$F(x^{(k+1)}) = F(x^{(k)} + \alpha^{(k)}p^{(k)}) = F(x^{(k)}) + \alpha^{(k)}\nabla F(x^{(k)})^T p^{(k)} + \cdots$$

che si può scrivere come

$$F(x^{(k+1)}) = F(x^{(k)} + \alpha^{(k)}p^{(k)}) = F(x^{(k)}) + \alpha^{(k)} < \nabla F(x^{(k)}), p^{(k)} > + \cdots$$

e richiediamo che si abbia

$$F(x^{(k)} + \alpha^{(k)}p^{(k)}) < F(x^{(k)}) \quad per \ \alpha^{(k)} > 0 \ ,$$
 (4)

allora la direzione  $p^{(k)}$  deve soddisfare la seguente condizione

$$<\nabla F(x^{(k)}), p^{(k)}> \quad <0$$


che rappresenta la condizione di direzione ammissibile.

Questa condizione ci dice che l'angolo fra la nuova direzione di discesa e il gradiente  $\nabla F(x^{(k)})$  deve avere coseno negativo (ricordiamo che  $<\nabla F(x^{(k)}), p^{(k)}>=$   $||\nabla F(x^{(k)})|| \cdot ||p^{(k)}|| \cos \theta$  dove l'angolo  $\theta$  è l'angolo fra i due vettori) cioè l'angolo  $\theta$  deve essere maggiore di  $\pi/2$  e minore di  $3\pi/2$ . 90 < alfa < 270

Poiché la condizione di ammissibilità per la direzione di discesa è data in funzione del gradiente della F(x) i metodi di discesa vengono anche chiamati metodi del gradiente.

### Es: Interpretazione geometrica dei metodi di discesa

Nel caso n = 2 la funzione F(x)=cost è rappresentata da ellissi concentriche il cui centro coincide con il minimo della funzione quadratica F(x) e costituisce la soluzione del problema. Il seguente grafico mostra quanto affermato dalla condizione di ammissibilità per la direzione di discesa.



# 4. Metodo della Discesa più Ripida (Steepest Descent)

Il metodo di Discesa più Ripida (Steepest Descent) è caratterizzato dalla scelta, ad ogni passo k, della direzione p<sup>(k)</sup> come l'antigradiente della F calcolato nell'iterato k -esimo, ovvero

$$\underbrace{p^{(k)}} = -\nabla F(x^{(k)}) = -Ax^{(k)} + b = -r^{(k)}.$$
(5)

Poiché il gradiente è la direzione di massima crescita, questo significa che ad ogni passo il vettore p<sup>(k)</sup> essendo l'antigradiente di F coincide con la direzione di massima decrescita.

In questo caso la (3) diventa

$$\alpha^{(k)} = -\frac{\langle r^{(k)}, p^{(k)} \rangle}{\langle Ap^{(k)}, p^{(k)} \rangle} = \frac{\langle r^{(k)}, r^{(k)} \rangle}{\langle Ar^{(k)}, r^{(k)} \rangle}$$

e

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)}p^{(k)}.$$

# Algoritmo steepest descent (Algoritmo del gradiente)

- 1. Parti con qualche  $x^{(0)}$ , k = 0
- 2. Calcola la direzione di discesa più ripida

$$p^{(k)} = -\nabla f(x^{(k)}) = - r^{\mathsf{K}}$$

3. Scegli lo stepsize  $\alpha^{(k)}$  tale che

$$F(x^k + \alpha^{(k)} p^{(k)}) < F(x^{(k)})$$

$$\alpha^{(k)} = \frac{\langle r^{(k)}, r^{(k)} \rangle}{\langle Ar^{(k)}, r^{(k)} \rangle}$$

4. Aggiorna l'iterato

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}$$
$$r^{(k+1)} = r^{(k)} + \alpha^{(k)} A p^{(k)}$$

5. Incrementa il contatore k=k+1

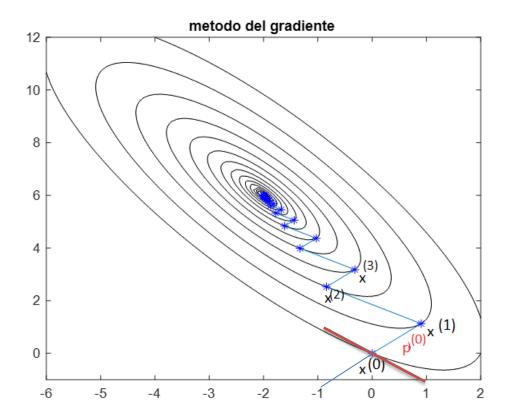
Fino a convergenza

Si considera che il procedimento iterativo ha raggiunto la convergenza quando  $||r^{(k+1)}||_2 \leq tolleranza$ 

# **Esempio**

$$A = \begin{bmatrix} 8 & 4 \\ 4 & 3 \end{bmatrix}$$
  $b = \begin{bmatrix} 8 \\ 10 \end{bmatrix}$   $x = \begin{bmatrix} -2 \\ 6 \end{bmatrix}$ 

Iterato iniziale  $x^{(0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ 



La direzione  $p^{(0)}$  è opposta alla direzione del gradiente alla curva di livello  $F(x^{(0)}) = cost$  nel punto  $x^{(0)}$  (Ricordiamo che il gradiente  $\nabla F(x^{(0)}) = r^{(0)}$  è perpendicolare alla tangente alla curva di livello nel punto  $x^{(0)}$ .

L'iterato  $x^{(1)}$  si trova a partire da  $x^{(0)}$  nella direzione di  $p^{(0)}$  nella posizione individuata da  $\alpha^{(1)}$ ,  $x^{(1)} = x^{(0)} + \alpha^{(1)}p^{(0)}$ .

Dal grafico si **nota** carattere a zigzag del metodo del gradiente, dovuto al fatto che il gradiente di una iterata è ortogonale al gradiente di quello precedente. Si noterà che, nonostante la convergenza dell'algoritmo, quest'ultimo è relativamente lento a causa di questo avanzamento a zig zag.

### Velocità di Convergenza

La velocità di convergenza di un metodo iterativo si può misurare considerando di quanto si è ridotto l'errore iniziale alla k-esima iterazione.

Per misurare l'errore si definisce la norma indotta dalla matrice simmetrica definita positiva A su x come

$$||x||_A^2 = x^T A x$$
.

Per il metodo del gradiente Steepest Descent vale la seguente relazione

$$\|x^{(k)} - x^*\|_A \le \left(\frac{K(A) - 1}{K(A) + 1}\right)^k \cdot \|x^{(0)} - x^*\|_A$$

Pertanto, definendo l'errore al passo k

$$e_{A}^{(k)} = ||x^{(k)} - x^{*}||_{A}$$

si ha

$$e_A^{(k)} \leq \left(\frac{K(A)-1}{K(A)+1}\right)^k) \cdot e_A^{(0)} \qquad \text{Autovalore max / Autovalore min}$$
 dove  $K(A)$  è l'indice di condizionamento di A, dato da  $K(A) = ||A|| \cdot ||A^{-1}|| = \lambda_{\max}/\lambda_{\min}$ .

Tanto più K(A) è alto tanto più il rapporto  $\left(\frac{K(A)-1}{K(A)+1}\right) \approx 1$  e quindi tanto più è lenta la convergenza.

(Abbiamo visto la definizione in norma 2 dell'indice di condizionamento di una matrice:

$$K_2(A) := \frac{\sqrt{\lambda_{max}(A^T A)}}{\sqrt{\lambda_{min}(A^T A)}}$$

Si dimostra che se A è una matrice simmetrica

$$K_2(A) := \frac{\sqrt{\lambda_{max}(A^T A)}}{\sqrt{\lambda_{min}(A^T A)}} = \frac{\sqrt{(\lambda_{max}(A))^2}}{\sqrt{(\lambda_{min}(A))^2}} = \frac{\lambda_{max}(A)}{\lambda_{min}(A)},$$

Poiché la funzione quadratica F(x) data dalla (2) assegnata la F(x)=cost rappresenta l'espressione di un iperellissoide con eccentricità legata dal rapporto  $\frac{\lambda_{max}}{\lambda_{min}}$ , possiamo dire che ad una matrice A mal condizionata corrisponde un' iperellissoide molto allungato, mentre ad un K(A) piccolo corrisponde un iperellissoide più arrotondato.