# Operazioni di macchina tra numeri macchina

L'insieme dei Numeri di Macchina (o Insieme Floating Point) è definito come l'insieme dei numeri reali esattamente rappresentabili con quel calcolatore.

$$F(\beta, t, L, U) = \{0\} \cup \left\{ \alpha \in R \setminus \{0\} : \alpha = sign(\alpha) 0. \, a_1 a_2 \dots a_t \, \beta^p = sign(\alpha) \left( \sum_{i=1}^t a_i \beta^{-i} \right) \beta^p \right\}$$

Base di rappresentazione  $\beta$ 

t cifre per la mantissa

Esponenti minimi e massimi L e U (L < 0, U > 0)

$$\begin{split} fl(\alpha) \in F(\beta, t, L, U) = \begin{cases} 0 & \text{se } \alpha = 0 \\ \pm m_t \beta^p & \text{se } \alpha \neq 0 \end{cases} \\ m_t = a_1 \beta^{-1} + a_2 \beta^{-2} + \cdots + \tilde{a}_t \beta^{-t} & \text{con } a_1 \neq 0. \end{split}$$

o equivalentemente:

$$fl(\alpha) = \pm 0. a_1 a_2 \dots \tilde{a}_t \beta^p$$
.

dove

• nel caso di troncamento  $\tilde{a}_t = a_t$ ; nel caso di arrotondamento (usato se  $\beta$  è pari) :

$$\frac{|\alpha - fl(\alpha)|}{|\alpha|} \le \begin{cases} \beta^{1-t} \text{ (caso di troncamento)} \\ \frac{1}{2}\beta^{1-t} = \mathbf{u} \text{ (caso di arrotondamento)} \end{cases}$$

$$|\varepsilon| \le u$$
 e  $fl(\alpha) = \alpha(1+\varepsilon)$ 

In doppia precisione t=53 corrisponde ad avere circa 16 cifre decimali significative,

infatti 
$$u = \frac{1}{2}2^{-52} = 2^{-53} \cong 10^{-16}$$

Errore relativo della somma finita tra due numeri di macchina e la somma calcolata in aritmetica reale: Assumiamo  $x, y \in R$ , ma  $x, y \notin F$ .

Pertanto, x e y devono innanzitutto essere arrotondati in F:

$$x \to fl(x) = x(1 + \epsilon_x) \in F, \ y \to fl(y) = y(1 + \epsilon_y) \in F,$$

$$fl(fl(x) \oplus fl(y)) = \left[x(1 + \epsilon_x) + y(1 + \epsilon_y)\right](1 + \epsilon_s) \qquad |\epsilon_x| \le u, |\epsilon_y| \le u, |\epsilon_s| \le u,$$

$$\left|\frac{x + y - fl(fl(x) + fl(y))}{x + y}\right| \approx \left|\frac{x}{x + y} \epsilon_x + \frac{y}{x + y} \epsilon_y + \epsilon_s\right| \le \left|\frac{x}{x + y} u + \frac{y}{x + y} u + u\right|$$

<u>Se x e y hanno lo stesso segno allora  $\left| \frac{x}{x+y} \right| \le 1$  e  $\left| \frac{y}{x+y} \right| \le 1$  e di conseguenza</u>

$$\left| \frac{x + y - fl(fl(x) + fl(y))}{x + y} \right| \le 3u$$

<u>Se x e y non hanno lo stesso segno</u> e sono vicini in modulo allora  $\left| \frac{x}{x+y} \right|$  e  $\left| \frac{y}{x+y} \right|$  possono crescere in maniera

incontrollata e rappresentare dei fattori di amplificazione degli errori di arrotondamento e quindi portano ad avere un errore relativo elevato.

**NB.** Se x e y sono rappresentabili esattamente in F, e quindi  $\epsilon_x = \epsilon_y = 0$ , allora la situazione non è pericolosa numericamente.

Errore relativo del prodotto in aritmetica finita tra due numeri di macchina ed il prodotto calcolato in aritmetica reale:

Assumiamo  $x, y \in R$ , ma  $x, y \notin F$ .

Pertanto, x e y devono innanzitutto essere arrotondati in F:

$$x \to fl(x) = x(1 + \epsilon_x) \in F, \ y \to fl(y) = y(1 + \epsilon_y) \in F,$$
$$fl(fl(x) \otimes fl(y)) = [x(1 + \epsilon_x) \cdot y(1 + \epsilon_y)](1 + \epsilon_p)$$
$$|\epsilon_x| \le u, |\epsilon_y| \le u, |\epsilon_p| \le u,$$

$$\left| \frac{x \cdot y - fl(fl(x) \otimes fl(y))}{x \cdot y} \right| = \frac{\left| x \cdot y(1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_p) - xy \right|}{\left| xy \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_p) - 1 \right|}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_p) - 1 \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - 1 \right|}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy} \right|}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y) - xy}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)} \right|} = \frac{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)}{\left| (1 + \epsilon_x)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)(1 + \epsilon_y)} \right|}$$

$$\left|\frac{x\cdot y - fl(fl(x)\otimes fl(y))}{x+y}\right| \leq 3u$$

Quindi qualunque siano i numeri  $x, y \in R$ , da cui si parte, l'errore relativo sul prodotto è sempre minore o uguale a 3u.

La somma algebrica macchina (addizione e sottrazione) tra due numeri  $x, y \in F(\beta, t, L, U)$  richiede le seguenti fasi:

- 1. Si scala la mantissa del numero con l'esponente minore in modo tale che i due addendi abbiano lo stesso esponente (ovvero quello dell'esponente maggiore);
- 2. Si esegue la somma tra le mantisse;
- 3. Si normalizza il risultato aggiustando l'esponente in modo tale che la mantissa sia un numero minore di 1.
- 4. Si arrotonda (o si tronca) la mantissa alle prime t cifre;

Consideriamo per esempio i numeri 
$$x, y \in F(10, 5, L, U)$$
  
 $x = 0.78546 \cdot 10^{2}, y = 0.61332 \cdot 10^{-1}$ 

e calcoliamo il numero macchina x \( \oplus \) y

- 1. Scaliamo y in maniera tale che abbia la stessa parte esponente di x
  - $y = 0.61332 \cdot 10^{-1} \cdot (10^{-2}) \cdot (10^{2}) = 0.00061332 \cdot 10^{2}$
- 2. Sommiamo le mantisse:  $0.78546 \cdot 10^2 + 0.00061332 \cdot 10^2 = 0.78607332 \cdot 10^2$
- 3. Il risultato in questo caso è già normalizzato.
- 4.  $fl(0.78607332 \cdot 10^2) = 0.78607 \cdot 10^2$

Consideriamo per esempio la differenza tra i due numeri

$$x = 0.75869 \cdot 10^2, y = 0.75868 \cdot 10^2$$

esattamente rappresentabili nell'insieme F(10, 5, L, U)

$$fl(x-y) = fl(0.75869 \cdot 10^2 - 0.75868 \cdot 10^2) = fl(0.00001 \cdot 10^2) = 0.1000 \cdot 10^{-2}$$
Normalizzazione dove a1 != 0 e il numero <1

In aritmetica reale:

$$x - y = 0.75869 \cdot 10^{2} - 0.75868 \cdot 10^{2} = 0.1000 \cdot 10^{-2}$$

Nonostante ci sia la cancellazione di cifre significative, la situazione non è pericolosa, infatti l'errore relativo è nullo

$$E_{rel} = \frac{|x - y - fl(x - y)|}{|x - y|} = \frac{|0.1000 \cdot 10^{-2} - 0.1000 \cdot 10^{-2}|}{|0.1000 \cdot 10^{-2}|} = 0$$

Questo è giustificato, come abbiamo visto in teoria, dal fatto che i dati x e y sono rappresentabili esattamente in nell'insieme F(10, 5, L, U)

Consideriamo adesso la differenza tra i due numeri

$$x = 0.75868531 \cdot 10^2, y = 0.75868100 \cdot 10^2$$

nell'insieme F(10, 5, L, U), in cui x ed y non sono esattamente rappresentabili.

$$fl(x) = 0.75869 \cdot 10^2$$
  $fl(y) = 0.75868 \cdot 10^2$ 

$$fl(fl(x) - fl(y)) = fl(0.75869 \cdot 10^2 - 0.75868 \cdot 10^2) = fl(0.00001 \cdot 10^2)$$

Normalizzazione della mantissa

$$0.00001 \cdot 10^2 = 0.00001 \cdot 10^4 \cdot (10^{-4}) \cdot 10^2 = 0.10000 \cdot 10^{-2}$$

$$fl(fl(x) - fl(y)) = 0.10000 \cdot 10^{-2}$$

In aritmetica reale:

$$x - y = 0.430999...10^{-3}$$

Calcoliamo l'errore relativo che commettiamo quando al posto del calcolo della somma in aritmetica reale sostituiamo il calcolo della somma in aritmetica finita:

$$\frac{|x-y-fl(fl(x)-fl(y))|}{|x-y|} = \frac{|0.430999...10^{-3}-0.10000.10^{-2}|}{|0.430999...10^{-3}|} \approx 1.32016$$

L'errore relativo commesso è del 132.016%

Perché x e y hanno segno diverso e vicini in modulo

# Il prodotto macchina tra due numeri $x, y \in F(\beta, t, L, U)$

richiede le seguenti fasi:

- 1. Si esegue il prodotto tra le mantisse;
- 2. Si esegue l'arrotondamento (o il troncamento) alle prime t cifre;
- 3. Si sommano gli esponenti, normalizzando, se necessario, la mantissa ad un numero minore di 1.

#### **Esempio:**

Consideriamo per esempio il prodotto tra i due numeri

$$x = 0.11111 \cdot 10^3$$
,  $y = 0.52521 \cdot 10^2$ 

nell'insieme F(10, 5, L, U).

- 1. Il prodotto delle mantisse produce 0.05835608;
- 2. L'arrotondamento a 5 cifre produce  $0.58356 \cdot 10^{-1}$
- 3. Somma degli esponenti  $x * y = 0.58356 \cdot 10^{-1} \cdot 10^3 \cdot 10^2 = 0.58356 \cdot 10^{-1} \cdot 10^5 = 0.58356 \cdot 10^4$

# La divisione macchina tra due numeri numeri $x, y \in F(\beta, t, L, U)$ richiede le seguenti fasi:

- 1. Si scala il dividendo x finchè la sua mantissa non risulti minore di quella del divisore y;
- 2. Si esegue la divisione tra le mantisse;
- 3. Si esegue l'arrotondamento (o il troncamento) alle prime t cifre;
- 4. Si sottraggono gli esponenti

#### (x) dividendo / (y) divisore

Consideriamo la divisione tra i due numeri

$$x = 0.12100 \cdot 10^5, y = 0.11000 \cdot 10^2$$

nell'insieme F(10, 5, L, U)

- 1. Scaliamo il dividendo di una cifra decimale  $0.012100 \cdot 10^6$  (in questo modo la sua mantissa risulta minore di quella del divisore);
- 2. Dividiamo le mantisse 0.01210/0.11000 = 0.11000;
- 3. Il troncamento fornisce lo stesso numero 0.11000;
- 4. Si sottraggono gli esponenti ottenendo il risultato

$$fl\left(\frac{x}{y}\right) = 0.11000 \cdot 10^4$$

# In $F(\beta, t, L, U)$

Non vale la proprietà associativa di somma e prodotto; (a+b)+c != a+(b+c) || (ab)c != a(bc) Non vale la proprietà distributiva della somma rispetto al prodotto. a(b+c) != ab+ac

### Esempio 1: (La somma tra numeri finiti non gode della proprietà associativa)

Sia  $\beta$ =10, e t=8. Dati i numeri reali a=0.23371258 · 10<sup>-4</sup> ,b=0.33678429 · 10<sup>2</sup> ,c= -0.33677811 · 10<sup>2</sup> a



b



C



I numeri a,b,c appartengono ad F. Calcoliamo fl(fl(a+b)+c) e fl(a+fl(b+c))

1) 
$$fl(fl(a+b)+c)$$

Si trasforma il numero a con esponente minore rispetto b in modo che i numeri abbiano lo stesso esponente

$$0.23371258 \cdot 10^{-4} = (0.23371258 \cdot 10^{-4})10^{-2} \cdot 10^{2} = 0.00000023371258 \cdot 10^{2}$$

a 10<sup>2</sup> b 10<sup>2</sup> 10<sup>2</sup>  $fl(a + b) = fl(0.33678452371258 \cdot 10^2) = 0.33678452 \cdot 10^2$  $10^2$ fl(a + b) $10^2$ С 10<sup>2</sup>

### Normalizzazione della mantissa e conseguente aggiustamento dell'esponente:

$$0.00000641 (10^{+5})(10^{-5})(10^{+2}) = 0.6410000 (10^{-3})$$



2) Calcoliamo adesso fl(a + fl(b + c))

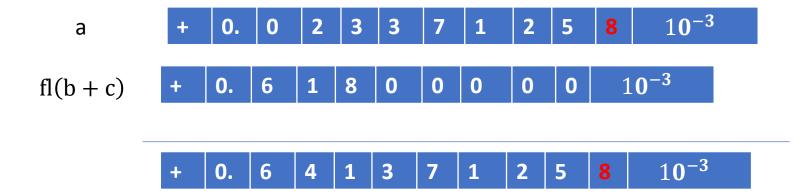


c - 0. 3 3 6 7 7 8 1  $10^2$ 

+ 
$$\begin{vmatrix} 0 & 0 & 0 & 0 & 0 & 6 & 1 & 8 & 10^2 \end{vmatrix}$$

## Normalizzazione della mantissa e conseguente aggiustamento dell'esponente:

$$fl(b+c) = 0.00000618 (10^{+5})(10^{-5})(10^{+2}) = 0.6180000 (10^{-3})$$



fl(a + fl(b + c)) =

Il risultato in aritmetica reale è  $a+b+c = 0.641371258 \cdot 10^{-3}$ 

**Esercizio 2:** Si consideri l'equazione

$$ax^2 + bx + c = 0$$

e sia  $\beta = 10$  e t=4 cifre.

$$a = 1$$
,  $b = -6.433$ ,  $c = 0.009474$ 

Calcoliamo le radici dell'equazione in aritmetica finita.

$$x_1 = \frac{-b - \sqrt{b^2 - 4ac}}{2a}$$

$$x_2 = \frac{-b + \sqrt{b^2 - 4ac}}{2a}$$

a=

+

).

1

0

3

10<sup>1</sup>

b=

-

6

4

3

10<sup>1</sup>

C=

+

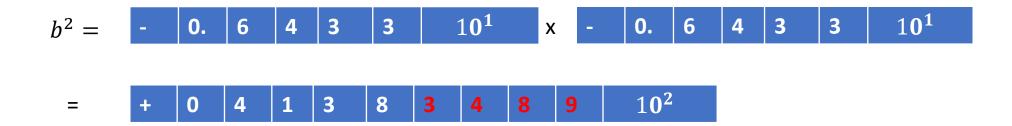
. |

7

4

 $10^{-2}$ 

Calcoliamo fl $(\sqrt{fl(b^2)} - \text{fl}(4ac))$ 



$$fl(b^2) =$$
 + 0. 4 1 3 8  $10^2$ 

$$4ac$$
 + 0. 9 4 7 4  $10^{-2}$  x + 0. 4 0 0 0  $10^{1}$  =

$$(0.9474 \cdot 0.4)10^{-2} \cdot 10^{1} = 0.37896 \cdot 10^{-2} \cdot 10^{1} = 0.37896 \cdot 10^{-1}$$

**Approssimazione per troncamento** 

$$fl(b^2)$$
 + 0. 4 1 3 8  $10^2$ 

$$fl(4ac)$$
 + 0. 3 7 8 9  $10^{-1}$ 

Si trasforma il numero con esponente minore in modo che i numeri abbiano lo stesso esponente

$$0.3789 (10^{-1})(10^{-2})(10^{+2}) = 0.0003789 (10^{2})$$

$$fl(b^2)$$
 + 0. 4 1 3 8

$$fl(4ac)$$
 + 0. 0 0 0 3 7 8 9  $10^2$ 

$$fl(b^2) - fl(4ac)$$
 + 0 4 1 3 4 2 1 1  $10^2$ 

$$\eta = fl(fl(b^2) - fl(4ac)) = +$$
 0. 4 1 3 4 10<sup>2</sup>

$$-b$$
 + 0. 6 4 3 3  $10^{1}$ 

$$fl(\sqrt{\eta})$$
 + 0. 6 4 2 9  $10^{1}$ 

$$-b - fl(\sqrt{\eta}) =$$
 + 0. 0 0 0 4  $10^{1}$ 

#### Normalizzazione della mantissa e conseguente aggiustamento dell'esponente:

$$\gamma = \text{fl}\left(-b - fl(\sqrt{\eta})\right) = 0.0004 \cdot (10^3) (10^{-3}) 10^1 = 0.4000 \cdot 10^{-2}$$

$$fl(x_1) = fl(\frac{\gamma}{2})$$
 + 0. 2 0 0 10<sup>-2</sup>

Calcoliamo adesso la radice  $x_2$ 

-k

+ 0. 6 4 3  $3 10^1$ 

 $fl(\sqrt{\eta})$ 

+ 0. 6 4 2 9  $10^1$ 

+

 $-b + fl(\sqrt{\eta}) =$ 

+ 1. 2 8 6 2  $10^1$ 

+  $\begin{vmatrix} 0 & 1 & 2 & 8 & 6 & 2 & 10^2 \end{vmatrix}$ 

$$\gamma = \text{fl}(-b + fl(\sqrt{\eta})) = + 0. \quad 1 \quad 2 \quad 8 \quad 6 \quad 10^2$$

$$fl(x_2) = fl(\frac{\gamma}{2})$$
 + 0. 6 4 3 0  $10^1$ 

In conclusione, le due soluzioni dell'equazione di partenza calcolare in aritmetica finita con  $\beta=2\,$  e  $t=4\,$ 

$$fl(x_1) = fl(\frac{\gamma}{2})$$
 + 0. 2 0 0 0  $10^{-2}$   $fl(x_2) = fl(\frac{\gamma}{2})$  + 0. 6 4 3 0  $10^{1}$ 

In aritmetica reale:

$$x_1 = \frac{6.433 - \sqrt{41.383489 - 0.037896}}{2} = \frac{6.433 - 6.4300538}{2} = 0.001473056 \dots$$
$$= 0.1473056 \dots 10^{-2}$$

$$x_2 = \frac{6.433 + \sqrt{41.383489 - 0.037896}}{2} = \frac{6.433 + 6.4300538}{2} = 6.431526943899537$$
$$= 0.6431526943899537 \dots \cdot 10^1$$

Errore relativo sul calcolo delle due soluzioni in aritmetica finita rispetto alle soluzioni calcolare in aritmetica reale:

$$\frac{|x_1 - fl(x_1)|}{|x_1|} = \frac{\left|0.1473056...\cdot10^{-2} - 0.2000\cdot10^{-2}\right|}{|0.1473056...\cdot10^{-2}|} \approx 0.36$$

L'errore relativo sul calcolo della soluzione  $x_1$  è del 36%

$$\frac{|x_2 - fl(x_2)|}{|x_1|} = \frac{|0.6431526943899537 \dots \cdot 10^1 - 0.6430 \cdot 10^1|}{|0.6431526943899537 \dots \cdot 10^1|} \approx 0.2374 \cdot 10^{-3}$$

L'errore relativo sul calcolo della soluzione  $x_2$  è dello 0.02374%

Un algoritmo più efficiente per il calcolo delle radici di un'equazione di II° grado è il seguente: calcolo la radice che, in base al segno di b, non porta problemi, cioè evita la differenza tra numeri molto vicini in modulo, nel nostro caso si suggerisce di calcolare  $x_2$  e poi calcolare  $x_1$ , tenendo conto della relazione che lega le due radici di un'equazione di secondo grado:  $x_1x_2 = \frac{c}{a}$  e quindi  $x_1 = \frac{c}{ax_2}$ 

$$fl(x_1) = fl\left(\frac{c}{ax_2}\right) = fl\left(\frac{0.9474 \cdot 10^{-2}}{0.6430 \cdot 10^1}\right) = fl(0.1473405909797823... 10^{-2}) = 0.1473 \cdot 10^{-2}$$

Rivalutiamo adesso l'errore relativo sul calcolo della soluzione  $x_1$ 

$$\frac{|x_1 - fl(x_1)|}{|x_1|} = \frac{|0.1473056...\cdot10^{-2} - 0.1473\cdot10^{-2}|}{|0.1473056...\cdot10^{-2}|} \approx 0.3808440341125482 \cdot 10^{-6}$$

L'errore relativo sul calcolo della soluzione  $x_2$  è dello 0.000038%